

# 基于改进 Sigmoid 卷积神经网络的手写体数字识别

樊继慧<sup>1,2</sup> 滕少华<sup>3</sup> 金弘林<sup>2</sup>

1 圣保罗大学研究生院 卡加延土格加劳 3500

2 广州理工学院计算机科学与工程学院 广州 510540

3 广东工业大学计算机学院 广州 510006

**摘要** 深度学习技术在数字识别领域有着普遍的应用。通过深度学习技术构造神经网络模型,运用不同的激活函数搭配不同的参数初始化策略,对 MNIST 手写数据集进行训练;构建分析模型,识别图像中的数字,将大数据量的图片降维成小数据量图片,同时保证能够有效保留图片特征;通过对图片数据的分析,加入特征转换过程,利用梯度下降优化器,搭建网络结构,将数据降维,有效地避免过拟合;利用交叉熵验证对模型进行编译和训练,对输出的分类结果进行进一步分析,在 Sigmoid 激活函数的输出层,通过  $K$  最近邻分类算法,设置 KNN 分类器,进一步提高了分类预测的准确率。MNIST 数据集上的实验结果显示识别率为 96.2%,在输出层引入  $K$  最近邻算法 KNN( $K$ -Nearst Neighbors)结合传统卷积神经网络(Convolutional Neural Network, CNN)的全连接层与 softmax 层,经交叉验证得到 99.6% 的识别率。

**关键词:** 数字识别;  $K$  最近邻算法; 深度学习; 卷积神经网络; 交叉熵

中图法分类号 TP391

## Handwritten Numeral Recognition Based on Improved Sigmoid Convolutional Neural Network

FAN Ji-hui<sup>1,2</sup>, TENG Shao-Hua<sup>3</sup> and JIN Hong-Lin<sup>2</sup>

1 Graduate School, St. Paul University Philippines, Tuguegarao, Cagayan 3500, Philippines

2 School of Computer Science and Engineering, Guangzhou Institute of Science and Technology, Guangzhou 510540, China

3 School of Computer Science and Engineering, Guangdong University of Technology, Guangzhou 510006, China

**Abstract** Deep learning technology is widely used in the field of number recognition. It constructs neural network model through deep learning technology, nonlinear transformation activation function in neurons, different activation functions with different parameter initialization strategies, trains MNIST handwritten data set, constructs analysis model and recognizes numbers in images, reduce the dimension of a large amount of data into a small amount of data, and ensure the effective retention of image features. Through the analysis of image data, adding the feature conversion process, using the gradient descent optimizer to build a network structure and reduce the dimension of data, which can effectively avoid over fitting. Cross-entropy verification is used to compile and train the model, and the output classification results are further analyzed. Through the  $K$ -nearest neighbor classification algorithm, KNN classifier is set to further improve the accuracy of classification and prediction. Through MNIST data set experiment, the recognition rate is about 96.2%. The  $K$ -nearest neighbor algorithm(KNN) is introduced into the output layer, combined with the full connection layer and softmax layer of traditional convolutional neural network(CNN). After cross verification, the recognition rate is 99.6%.

**Keywords** Digital identification,  $K$  nearest neighbor algorithm, Deep learning, Convolutional neural network, Cross entropy

## 1 引言

图像识别的发展经历了 3 个阶段,从文字识别到数字图像处理与识别,最后是物体识别。我们运用机器学习的思想

将此类识别问题转化为分类问题。

手写数字识别技术发展迅速,识别的准确度和速度都在不断提高。由于拍照扫描设备在不同光照、分辨率、书写纸张等条件下会呈现不同的效果,这就给机器识别带来了困难,

到稿日期:2021-10-25 返修日期:2022-02-25

基金项目:国家自然科学基金(61972102);广东省教育厅重大专项(2021ZDZX1070);广东省高等教育研究课题(22GQN37);校本研究项目(2021XBZ03)

This work was supported by the National Natural Science Foundation of China(61972102), Major Special Projects of Guangdong Provincial Department of Education(2021ZDZX1070), Guangdong Higher Education Research Project(22GQN37) and School Based Research Project(2021XBZ03).

通信作者:樊继慧(2519639989@qq.com)

同时,数字化也会带来一定的噪声干扰。

数字手写体识别相对来说较为简单,由于其有限的类别(0~9 共 10 个数字)有助于深入分析和验证一些理论,因此成为了相对简单的手写识别任务。本文以 MNIST 数据集为例进行分析研究。MNIST 数据集涉及的数字虽然少,但是这是一种全球通用的语言,各个国家写法千差万别,带有明显的区域性特征,在实际的生活中,对数字的正确率要求也非常高,这些数字往往跟一些密码、银行账户、身份证等关键信息相关,因此对准确率的要求更加苛刻,所以研究高性能的手写数字识别算法是重中之重。有学者设计并实现了一种基于 Zynq 平台的卷积神经网络单元,利用 Zynq 平台上 FPGA 端可并行计算的特性,对卷积神经网络中的卷积层进行加速处理,运用高层次综合(High-Level Synthesis, HLS)进行卷积层以及池化层 IP 核的设计与实现,提出了一些优化方案,最终实现了在嵌入式平台上对手写数字的高效识别<sup>[1]</sup>。

之前有研究使用神经网络实现手写数字的识别。此前的神经网络是由两层网络组成,第一层是线性层,共由 10 个偏置以及  $784 \times 10 = 7840$  个权重组成,由于结构比较简单,并未设置激活函数,通过第二层的 softmax 层,最后的准确率只有 91.2%。我们进行了改进,在加上  $k$  最近邻算法后的准确率可以达到 98.7%,利用其使用类别标签的优点,使网络学习更多的特征。最后,改进判别器为分类器,并提出新的损失函数,加快收敛速度,提高识别精度<sup>[2]</sup>。

首先构建数学神经元结构,如图 1 所示。




图 1 神经元结构

Fig. 1 Neuron structure

其中,  $x_j$  为输入信号,  $f$  为传递函数,  $w_{i,j}$  表示与神经元  $x_j$  连接的权值,  $y_i$  表示输出值,  $\theta$  表示阈值,由此形成 BP 网络结构,如图 2 所示。每一轮将训练得到的结果与预想结果进行误差分析,进而修改权值和阈值,一步步得到输出和预想结果一致的模型。




图 2 BP 网络结构

Fig. 2 BP network structure

也有学者将原始向量组进行邻近特征筛选,得出多维复合非正交特征向量组;将训练库所得的向量组与测试集的向量组进行对比,识别出所测试的手写数字<sup>[3]</sup>。

## 2 基于 CNN+KNN 的算法改进

MNIST 数据集来自美国国家标准与技术研究所。训练集(Training Set)由来自 250 个不同人手写的数字构成,其中 50% 是高中学生,50% 来自人口普查局(the Census Bureau)的工作人员;测试集(Test Set)也是基于同样比例的手写数字数据。

MNIST 数据集包括 70 000 张 0~9 的手写数字图像,每张图像包括 784 个像素值及一个标签。构建 KNN 分类器:设置查找算法以及邻居点数量( $k$ )值。KNN 是一种懒惰学习法,在预测分类时查找最近邻的点,数据集的输入就是构建 KNN 分类器的过程 `knn = neighbors. KNeighborsClassifier (algorithm='kd_tree', n_neighbors=3) knn. fit(train_data-Set, train_hwLabels)`。

有学者提出最近邻注意力和卷积神经网络的文本分类模型(CNN-AKNN),该模型通过引入基于加权卡方距离的最近邻改进算法训练文本,构建文本对象的注意力,然后将注意力机制与卷积神经网络相结合,实现全局特征与局部特征的提取,最后通过 softmax 函数进行文本分类<sup>[4]</sup>。

Training set images: train-images-idx3-ubyte. gz(9.9 MB, 解压后 47 MB, 包含 60 000 个样本); Training set labels: train-labels-idx1-ubyte. gz(29 kB, 解压后 60 kB, 包含 60 000 个标签); Test set images: t10k-images-idx3-ubyte. gz(1.6 MB, 解压后 7.8 MB, 包含 10 000 个样本); Test set labels: t10k-labels-idx1-ubyte. gz(5 kB, 解压后 10 kB, 包含 10 000 个标签)。

如表 1 所列,训练集文件包含偏移量、数据类型、值、说明 4 个属性。image 数据集是二进制存储,前 32 个字节为 4 个 int,分别表示 magic、num(图片个数)、rows(图像行数)以及 cols(列),之后每个字节就是图像的每个像素。labels 数据集前 16 个字节是两个 int,分别表示 magic 和 num,后面每个字节表示图像的数字,对应 images 里的每个图片。我们的目标是构建模型,识别图像中的数字。为了向网络提供训练数据,对数字图像进行了展平处理。在训练阶段和测试阶段,通过 KNN 分类器推送不同的示例,邻居个数分别取 1, 3, 5, 7 等值。训练过程基于标签,通过分类结果和实际结果的对比,得到正确率统计。

表 1 训练集标签文件(train-labels-idx1-ubyte)

Table 1 Training set label file(train-labels-idx1-ubyte)

offset	type	value	description
0000	32 bit integer	2049	Magic num
0004	32 bit integer	60 000	Num of items
0008	Unsigned byte	—	label
—	—	—	—
xxxx	Unsigned byte	—	label

The labels values are 0 to 9

加入特征转换过程后,占位符将填充在评估计算图时传递的值,在训练过程中调整权重和偏差的值,TensorFlow2 提供了不同的变量。权重的初始值将遵循正态分布,而偏差的值为 1.0。

在分析阶段,梯度下降优化器将分几个步骤工作,调整  $W$  和  $b$  变量的值。将 `tf. equal` 返回的布尔值列表强制转换为



通过对小样本的测试找到最优的卷积核数目,实验过程如下:第一层采取  $3 \times 3$  的正方形卷积核,个数为 20,深度为 1, stride 为 2, pooling 尺寸为  $2 \times 2$ , 激活函数采取 RELU; 第二层只对卷积核的尺寸、个数和深度进行调整,分别为  $5 \times 5$ , 50 和 20; 最后的链接层全连接输出层, 设定 10 个 label 作为输出, 采用 Softmax 函数作为分类器, 输出每个 label 的概率。我们通过实验记录卷积核参数对实验的影响, 结果如表 3 所列。

表 3 卷积核参数对实验的影响

Table 3 Influence of convolution kernel parameters on experiment

	层数	卷积核 尺寸	卷积核 个数	通道数 (channel)	池化 尺寸	步 长	time	result
原始 参数	第一层	5	20	1	2	2	4 m 13.729 s	98.93%
	第二层	5	50	20	20	2		
第一次 改进	第一层	3	20	1	2	2	4 m 20.276 s	98.99%
	第二层	3	50	20	20	2		
第二次 改进	第一层	3	20	1	2	2	4 m 48.579 s	99.01%
	第二层	3	100	20	20	2		

第一次改进: 仅改变第一层与第二层的卷积核数目的大小, 其他保持不变。可以看到结果提升了 0.06%。第二次改进: 保持  $3 \times 3$  的卷积核大小, 其他保持不变, 仅改变第二层的卷积核数目, 可以看到结果相较于原始参数提升了 0.08%。说明改变卷积核的大小与卷积核的数目会对结果产生一定的影响。在接下来的实验中, 将通过最优化卷积核数目来提高准确率。

KNN 算法实现: 计算出每一个样本点与测试点的距离, 选取距离最近的  $K$  个样本, 并获取它们的标签 label, 然后找出  $K$  个样本中数量最多的标签, 返回该标签。

卷积神经网络是一种多层感知器, 每层由二维平面组成, 每个平面又由多个独立的神经元组成, 我们把复杂元记为  $S$ , 简单元记为  $C$ , 简单元聚合构成卷积层, 复杂元构成下采样层, 把输入的图像加上滤波器以及可加偏置进行卷积, 在  $C$  层产生  $N$  个特征图, 特征映射图经过求和、加权和偏置, 通过 Sigmoid 激活函数得到  $S$  层的特征映射图。最后, 对最尾部的下采样和输出层进行全连接, 将输出结果输入下一层 KNN 分类器, 通过设置不同个数的邻居进行对比实验找到最优  $K$  值。 $f(X)$  是一个可以训练的滤波器, 利用  $f(X)$  去卷积一个输入的图像, 通过 Sigmoid 激活函数, 加一个偏置  $bx$ , 得到卷积层  $Cx$ 。具体的运算如下:

$$x_j^l = f \cdot \left( \sum_{i \in M_j} X_i^{l-1} * k_{ij}^l + b_j^l \right)$$

其中,  $M_j$  是输入特征图的值。

卷积神经网络的输入层可以处理多维数据, 隐含层包含卷积层、池化层和全连接层 3 类常见构筑, 算法中有 Inception 模块、残差块 (Residual Block) 等复杂构筑。在常见算法体系中, 卷积层和池化层为卷积神经网络特有。卷积层中的卷积核包含权重系数, 而池化层不包含权重系数。卷积层的功能是对输入数据进行特征提取, 其内部包含多个卷积核, 组成卷积核的每个元素都对应一个权重系数、一个偏差量 (Bias Vector) 以及一个前馈神经网络的神经元 (Neuron)。卷积层内每

个神经元都与前一层中位置接近的区域的多个神经元相连, 区域的大小取决于卷积核的大小。

利用梯度下降算法时需要在所有的训练数据上计算梯度, 由于计算量太大, 因此调用 next\_batch 方法, 先在所有的训练数据集中筛选一部分, 并随机选取其中一部分训练数据集, 将其提供给神经网络的输入层, 然后通过反向迭代方法优化这个神经网络。这里的  $xx$  设置为 100, 也就是说我们得到了  $xs$  和  $ys$  两个矩阵,  $xs$  代表输入数组, 相当于把一个  $28 \times 28$  的手写图像展开成一个长度为 748 的一维数组;  $ys$  相当于本文得出的结果, 也就是 0~9 这 10 种可能值。梯度下降算法的描述如算法 1 所示。

#### 算法 1 梯度下降算法

Inputs: loss function  $\epsilon$ , learning rate  $\eta$ , dataset  $X, y$  and the model  $F(\theta, x)$

Outputs: Optimum  $\theta$  which minimizes  $\epsilon$

REPEAT until converge:

$\tilde{y} = F(\theta, x)$

$$\theta = \theta - \eta \cdot \frac{1}{N} \sum_{i=1}^N \frac{\partial \epsilon(y, \tilde{y})}{\partial \theta}$$

End

输入一个训练数据集, 得到在当前数据集下的推导结果, 再将这个推导结果和正确答案进行比对。下一步我们定义 loss 函数, 它是评估当前模型好坏的指标之一, 在实验中相当于评价 cross\_entropy 加上正则化, 这里正则化是为了避免过耦合。通过 GradientDescentOptimizer 函数来优化。

我们定义一个 loss 函数来描述模型对问题的分类精度, loss 越小, 模型越精确。这里采用交叉熵: 损失函数/目标函数: 交叉熵来衡量两个概率分布之间的差异, 刻画两个概率分布之间的距离, 两个概率分布越接近, 这种困难程度就越小, 那么交叉熵就会越小。交叉熵越小, 就说明模型的输出越接近正确的结果。交叉熵表达为:

$$H_{y'}(y) = - \sum_i y_i' \log(y_i)$$

其中,  $y$  是我们预测的概率分布,  $y'$  是实际的分布。接着采用随机梯度下降法, 将步长设置为 0.5 进行训练。在训练模型时, 让模型循环训练 1000 次, 每次随机从训练集中提取 100 条样本, 以加快收敛速度。通过判断实际值和预测值是否相同来评估模型, 并计算准确率, 准确率越高, 分类越精确。

实验环境和配置: Python3.8 + TensorFlow2, windows64 位操作系统。

搭建网络的实现过程如下:

```
model = tf.keras.models.Sequential()
```

```
model.add(tf.keras.layers.Flatten(input_shape=(28, 28)))
```

```
model.add(tf.keras.layers.Dense(128, activation='relu'))
```

```
model.add(tf.keras.layers.Dense(10, activation='softmax'))
```

```
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy', metrics=['accuracy'])
```



训练模型的实现过程如下:

```
# model.fit(train_images, train_labels, verbose=2, epochs=5)
```

### 3 实验结果对比与分析

到目前为止,人们已经在手写数字识别技术中取得了很好的成就, TensorFlow2 作为端到端开源机器学习平台,生态系统相对比较完善,它包含各种工具和库,可以帮助研究人员实现对先进机器学习技术的深入研究,能够部署和支持各项应用。第一层:卷积层负责提取图像中的局部特征;第二层:池化层用来大幅降低参数量级(降维);第三层:全连接层负责输出结果;第四层:KNN+CNN 交叉验证,精准识别。

实现的整个算法流程如图 5 所示。

- (1) 定义算法公式,即神经网络前向传播时的计算。
- (2) 定义 loss,选定优化器,并指定优化器优化 loss。
- (3) 迭代地对数据进行训练。训练流程的 4 个步骤为:
  - 1) 计算输出;2) 计算损失函数;3) 通过损失函数计算梯度;4) 通过梯度更新权值。
- (4) 将训练结果导入 KNN 分类器,通过实验得出最优邻居。
- (5) 在测试集或验证集上对准确率进行评测。

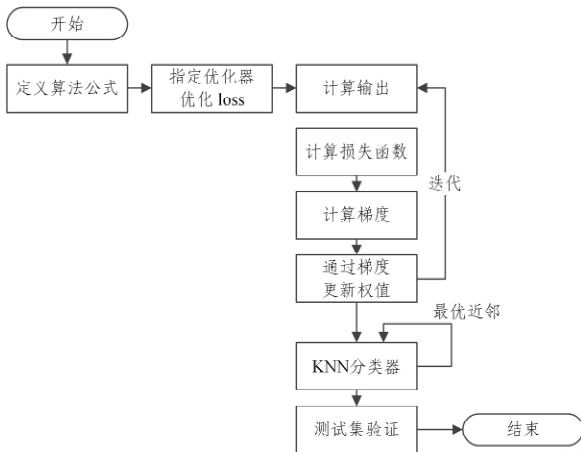


图 5 算法整体架构流程图

Fig. 5 Overall architecture of algorithm

表 4 列出了邻居数量  $K$  的不同取值对算法正确率的影响

Table 4 Comparison of recognition rates with different  $K$

$K$ value	1	3	5	7
Correct rate	0.962	0.976	0.996	0.980

与当下几种算法效率的对比结果表明(见表 4):没有添加 KNN 算法之前,分类准确率为 0.962,相对较低;加入 KNN 分类器后分类效果提升,达到 0.976,在  $K=5$  时分类效果最佳,达到 0.996。通过在 MNIST 数据集上的实验对比发现,识别率在 96.2% 左右。在输出层引入  $K$  最近邻算法(KNN)结合传统卷积神经网络(CNN)的全连接层与 softmax 层,经交叉验证得到 99.6% 的识别率。

与当下流行的几种手写数字识别算法的识别率进行对比,结果如图 6 所示。




图 6 不同算法识别率的对比

Fig. 6 Comparison of recognition rates of different algorithms

本文运用的基于 KNN+CNN 的手写数字识别算法的识别率为 99.6%,而基于改进型卷积神经网络的手写数字识别方法识别率为 99.2%<sup>[5]</sup>,基于改进 VGG-16 和朴素贝叶斯的手写数字识别方法的识别率为 99.36%<sup>[6]</sup>。

近年来,边缘智能得到了长足的发展,然而手写数字识别卷积网络模型的发展无法解决边缘部署和算力下降等各种问题,如果样本数量较少,那么泛化能力就较差,导致网络训练成本过高<sup>[7]</sup>。在构建神经网络时,神经元与神经元之间都对应着连接权值,所有的输入加权之和会决定当前神经元是处于哪种状态。此处的状态分为两大类:激活状态和抑制状态。感知器网络的输出形式取值为 0 或 1,在此引入 S 型可导函数,通过 S 型激活函数的处理之后才可输出。有学者提出了基于深度神经网络模型的手写体图像识别方法,让机器自动学习特征<sup>[8]</sup>,通过改进成本函数来提高识别率。

同时,也有学者依托神经网络算法来处理图片技术和海量优质数据,该算法可以支持识别各种不规则手写字体,尤其是对字迹潦草和模糊等情况进行专项优化,能够达到 90% 以上的准确率。Zeng 等针对不同笔体下的手写识别准确率进行研究和改进,将深度卷积神经网络与自动编码器相结合,设计了卷积自编码器网络层数,形成深度卷积自编码神经网络<sup>[9]</sup>。

对于手写数字,神经网络模型一般比逻辑回归模型的准确率更高。逻辑回归模型只能处理二维的输出,如果是高维的输出,则需要用多个模型来降维,而神经网络可以直接处理多维输出,实现基于卷积神经网络的手写体数字识别系统<sup>[10]</sup>。为了提高手写体数字的识别率,在 AlexNet 网络模型的基础上进行改进,引入 Inceptionresnet 模块替换模型中的 Conv3 和 Conv4 来提升模型的特征提取能力<sup>[11]</sup>。手写数字识别系统在手写小车中也有一定应用,整个手写数字识别小车系统在电脑端完成对数字的识别,然后通过无线蓝牙将识别的结果传输给智能小车,小车根据其识别的指令做出相应的响应动作<sup>[12]</sup>。Han 等以手写数字(MNIST)数据库为例,将原始向量组进行邻近特征筛选,得出多维复合非正交特征向量组,将训练库所得的向量组与测试集的向量组进行比对,识别出所测试的手写数字<sup>[13]</sup>,对手写数字识别算法进行提升和改进。也有学者通过集成深度迁移学习(EDTL)模型,提取相关特征作为全连接人工神经网络分类器的输入,采用 2 次卷积、2 次池化和 3 次全连接来提高识别的准确率<sup>[14]</sup>。 $K$ -最近邻 KNN( $K$ -Nearest Neighbors)算法不仅在手写数字识别领域应用广泛,在高光谱图像领域<sup>[15]</sup>也体现出了较好的分类优势。利用  $K$  近邻特征选择方法和距离加权<sup>[16]</sup>,在遗传

算法搜索最优特征权重向量中也取得了较好的效果。KNN 算法在文本分类时通过融入文本特征值的多峰分布和文本相似度的计算量<sup>[17]</sup>来提升分类效果。在垃圾短信的分类问题领域<sup>[18]</sup>, $K$ 最近邻算法也具备一定优势。

**结束语** 当 $k$ 取不同值时,分类算法给出的结果不尽相同,但是整体的识别率都有所提高。我们通过大量数据训练算法和梯度降维设计,找出对应的最适合系统的 $k$ 值,使算法在精度方面达到系统的要求。

神经网络模型的初始化参数非常重要。矩阵的运算效率通常比循环的运算效率高,本文的数据处理也采用矩阵形式。本文证实了将深度学习和 KNN 算法相结合能够实现更好的识别率。

### 参 考 文 献

- [1] YIN Z Y, XU G Y, ZHANG F Q, et al. Design and implementation of convolutional neural network unit for zynq platform [J/OL]. Small microcomputer system; 1-6. <http://kns.cnki.net/kcms/detail/21.1106.TP.20210413.1558.012.html>.
- [2] WANG A L, XUE D, WU H B, et al. Handwritten digit recognition based on conditional generation countermeasure network [J]. Liquid Crystal and Display, 2020, 35(12): 1284-1290.
- [3] MA Y X, GUO X J. Recognition of handwritten digits based on K-nearest neighbor algorithm [J]. Journal of Jilin Jianzhu University, 2021, 8(6): 84-86.
- [4] ZHU Y, CHEN S P. Text classification model of nearest neighbor attention and convolutional neural network [J]. Small Microcomputer System, 2020, 41(2): 375-380.
- [5] DUAN L L, ZHANG L. A handwritten numeral recognition method based on improved convolutional neural network [J]. Modern Electronic Technology, 2021, 44(18): 107-110.
- [6] WANG M, LI D X. Handwritten numeral recognition based on improved vgg-16 and naive Bayes [J]. Modern Electronic Technology, 2020, 43(12): 176-181, 186.
- [7] WANG J R, MA X, DUAN G L, et al. Handwritten numeral recognition under the background of edge intelligence [J]. Computer Applications, 2019, 39(12): 3548-3555.
- [8] SONG X R, WU X, GAO S, et al. Simulation Research on handwritten digit recognition based on deep neural network [J]. Science, Technology and Engineering, 2019, 19(5): 193-196.
- [9] ZENG W X, MENG Q L, GUO Z K. Research on handwritten digit recognition based on deep convolution self coding neural network [J]. Computer Application Research, 2020, 37(4): 1239-1243.
- [10] CHEN Y, LI Y Y, YU L, et al. Handwritten digit recognition system based on convolutional neural network [J]. Microelectronics and Computer, 2018, 35(2): 71-74.
- [11] XIE D Y, LI L H, MIAO C S. Handwritten digit recognition based on improved alexnet convolutional neural network [J]. Journal of Hebei University of Engineering, 2021, 38(4): 102-106.
- [12] DU X. Research and implementation of handwritten digit recognition car based on Wireless Bluetooth transmission [J]. Electronic Testing, 2022, 36(6): 8-10.
- [13] HAN X, LIU Q, XU J, et al. Handwritten numeral recognition algorithm based on pseudo PCA [J]. Computer Science, 2018, 45(S2): 278-281, 307.
- [14] GAO Y P, HU Z Y. Improvement of handwritten numeral recognition model based on keras [J]. Computing Technology and Automation, 2021, 40(2): 164-169.
- [15] ZHAO J L, HU L, YAN H, et al. Hyperspectral image classification method combining local binary mode and k-nearest neighbor algorithm [J]. Journal of Infrared and Millimeter Wave, 2021, 40(3): 400-412.
- [16] LI S J, ZHANG K X, WANG S D, et al. Feature selection method based on weighted k-nearest neighbor [J]. Journal of Tianjin Normal University (Natural Science Edition), 2020, 40(2): 63-67.
- [17] YIN Y B, YANG W Z, YANG H T, et al. Improved KNN Text Classification Algorithm Based on search [J]. Computer Engineering and Design, 2018, 39(9): 2923-2928.
- [18] HUANG W M, MO Y. Chinese spam message filtering based on text weighted KNN algorithm [J]. Computer Engineering, 2017, 43(3): 193-199.



**FAN Ji-hui**, born in 1990, postgraduate, lecturer. Her main research interests include data analysis and mining.

(责任编辑:何杨)